

PROYECTO 2 : INTERFAZ CEREBRO-COMPUTADOR (BCI)

LUISA FERNANDA LLAMAS BALDOVINO
CAMILA ANDREA MONTIEL ZAPATA

BIOSEÑALES



UNIVERSIDAD DE ANTIOQUIA
FACULTAD DE INGENIERÍA
BIOINGENIERÍA

MAYO 31 DE 202

1. INTRODUCCIÓN

Las interfaces cerebro-computador (BCI, por sus siglas en inglés Brain-Computer Interface) representan una tecnología emergente de alto impacto en el campo de la neurociencia computacional y la rehabilitación neurológica. Estos sistemas permiten establecer un canal de comunicación directo entre la actividad eléctrica del cerebro y dispositivos externos, sin necesidad de vías motoras convencionales. Su aplicación principal se orienta hacia la asistencia a personas con discapacidades motoras graves, tales como parálisis o enfermedades neurodegenerativas, en quienes la imaginación de movimientos puede ser decodificada para controlar prótesis, sillas de ruedas u otros actuadores [1].

El paradigma de imaginación motora constituye uno de los enfoques más estudiados en sistemas BCI basados en electroencefalografía (EEG). Durante la imaginación de movimientos, el sistema nervioso central genera patrones de actividad electroencefalográfica diferenciados que se manifiestan, principalmente, como cambios en la potencia de los ritmos sensoriomotores Mu (8–13 Hz) y Beta (13–30 Hz) en regiones corticales contiguas a la corteza motora primaria. El fenómeno de desincronización relacionada con eventos (ERD, Event-Related Desynchronization) que consiste en una supresión localizada de la potencia espectral durante la activación motora— proporciona la base fisiológica sobre la que se sustenta la discriminación de estados en este tipo de sistemas [2].

El principal desafío técnico de un sistema BCI basado en imaginación motora radica en la extracción de características discriminativas a partir de señales EEG de alta variabilidad intersujeto, alta dimensionalidad y relación señal-ruido limitada. La selección de índices adecuados espectrales, estadísticos, de complejidad y de conectividad funcional— y el diseño de clasificadores robustos son, por tanto, aspectos críticos que determinan la viabilidad y el desempeño del sistema [1].

El presente informe documenta el desarrollo completo de un pipeline de procesamiento de señales EEG para la clasificación triclase de estados mentales: reposo (T0), imaginación de movimiento de la mano izquierda (T1) e imaginación de movimiento de la mano derecha (T2). Los datos empleados corresponden a la base de datos pública PhysioNet EEG Motor Movement/Imagery Dataset (sujetos S001–S109), ampliamente utilizada como referencia en la comunidad investigadora. El pipeline integra cinco fases secuenciales: adquisición y preprocesamiento, segmentación por eventos, extracción de características multidominio, análisis estadístico de discriminabilidad, y clasificación mediante aprendizaje automático y aprendizaje profundo.

Los objetivos específicos del proyecto comprenden: (i) implementar el preprocesamiento de la señal EEG mediante filtrado espacial CAR y filtrado FIR pasabanda en las bandas Mu y Beta; (ii) extraer un conjunto de índices neurofisiológicos Densidad Espectral de Potencia (PSD), parámetros de Hjorth, Entropía Muestral (SampEn), Phase Locking Value (PLV) e Índice de Lateralidad (LI) sobre los canales sensoriomotores C3, Cz y C4; (iii) validar estadísticamente la capacidad discriminativa de dichas características mediante pruebas no paramétricas de Mann-Whitney U; y (iv) comparar el rendimiento de cinco modelos clasificadores —tres arquitecturas MLP, SVM con kernel RBF y XGBoost bajo un esquema de validación cruzada Stratified K-Fold con $k=5$.

2. MARCO TEÓRICO

2.1 Índices de EEG para la clasificación de estados en BCI.

2.1.1 Parámetros de Hjorth (Actividad, Movilidad, Complejidad)

Al analizar señales de EEG se implementan tres descriptores estadísticos del dominio temporal o parámetros de Hjort que caracterizan la señal sin necesidad de transformadas espectrales y estos son :

Actividad(varianza de la señal): Representa la potencia de la señal. Equivale a la superficie bajo la curva de densidad espectral de potencia.

Movilidad(desviación estándar de la derivada normalizada por la señal): Representa la frecuencia media del espectro de potencia (desviación estándar normalizada).

Complejidad(tasa de cambio de la movilidad): Compara la movilidad de la derivada con la de la señal original. Converge a 1 cuando la señal se asemeja a una onda sinusoidal pura; valores mayores indican mayor complejidad morfológica.

Parámetro	Ecuación
Actividad	$var(y(t))$
Movilidad	$\sqrt{\frac{var(y'(t))}{var(y(t))}}$
Complejidad	$\frac{mobility(y'(t))}{mobility(y(t))}$

Tabla 1. Parámetros de hjort[1]

2.1.2 STFT (Short-Time Fourier Transform)

Esta métrica permite analizar cómo varía el contenido frecuencial de la señal a lo largo del tiempo, lo que es esencial porque la señal es no estacionaria. Su resultado (espectrograma) puede usarse como característica directa o como base para calcular otros índices [3].

2.1.3 Entropía Muestral (Sample Entropy)

Esta es una medida que permite identificar la irregularidad/complejidad de la señal. La Sample Entropy cuantifica la probabilidad de que patrones similares en la señal se repitan. Valores bajos indican señales más predecibles (como reposo); valores altos, señales más complejas (como imaginación motora activa) [4].

2.1.4 Phase Locking Value (PLV)

Medida de sincronía de fase que cuantifica qué tan consistentemente dos electrodos mantienen una diferencia de fase en una banda de frecuencia dada (μ /beta para imaginación motora). Valores cercanos a 1 indican alta sincronía; cercanos a 0, independencia [5].

2.2 Métricas de evaluación de clasificación:

2.2.1 Precisión (Accuracy)

La precisión es una métrica de evaluación utilizada para medir el rendimiento general de un modelo de clasificación. Representa la proporción de predicciones correctas realizadas por el clasificador respecto al total de muestras evaluadas.[6]

Matemáticamente se define como:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

donde:

TP (True Positives): positivos correctamente clasificados.

TN (True Negatives): negativos correctamente clasificados.

FP (False Positives): negativos clasificados incorrectamente como positivos.

FN (False Negatives): positivos clasificados incorrectamente como negativos.

En sistemas BCI basados en EEG, la precisión permite determinar qué tan bien el algoritmo diferencia entre condiciones como reposo, imaginación de movimiento de mano derecha e imaginación de movimiento de mano izquierda. Una alta precisión indica que el modelo logra reconocer correctamente los patrones cerebrales asociados a cada tarea mental.

Sin embargo, esta métrica puede ser insuficiente cuando las clases no están balanceadas, por lo que suele complementarse con otras herramientas como la matriz de confusión[6].

2.2.1 Precisión (Precision)

La precisión mide qué proporción de las muestras clasificadas como pertenecientes a una clase realmente corresponden a esa clase. Esta métrica es útil cuando se desea minimizar los falsos positivos.

Se define como:

$$\text{Precisión} = \frac{TP}{TP + FP}$$

donde:

- **TP (True Positives):** muestras positivas correctamente clasificadas.
- **FP (False Positives):** muestras negativas clasificadas incorrectamente como positivas.

En aplicaciones BCI basadas en EEG, una alta precisión indica que cuando el sistema identifica una determinada condición, por ejemplo imaginación de movimiento de la mano derecha, existe una alta probabilidad de que dicha predicción sea correcta[6].

Recall o Sensibilidad

El Recall mide la capacidad del clasificador para detectar correctamente todas las muestras pertenecientes a una clase determinada. Es especialmente importante cuando se busca minimizar los falsos negativos.

Se calcula mediante:

$$\text{Recall} = \frac{TP}{TP + FN}$$

donde:

- **TP (True Positives):** muestras positivas correctamente clasificadas.
- **FN (False Negatives):** muestras positivas clasificadas incorrectamente como negativas.

En sistemas BCI, un alto Recall indica que el algoritmo logra reconocer la mayoría de los patrones cerebrales asociados a una condición específica, reduciendo la cantidad de eventos que pasan desapercibidos[7] .

2.2.3 F1-Score

El F1-Score es una métrica que combina Precisión y Recall en un único valor mediante su media armónica. Se utiliza cuando existe interés en equilibrar ambas métricas y es especialmente útil cuando las clases están desbalanceadas.

Se define como:

$$\text{F1} = 2 * \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

El F1-Score toma valores entre 0 y 1, donde valores cercanos a 1 indican un mejor desempeño del clasificador.

En aplicaciones BCI, esta métrica permite evaluar simultáneamente la capacidad del sistema para detectar correctamente una condición y evitar clasificaciones erróneas, proporcionando una medida más robusta que la precisión global (Accuracy)[8] .

2.2.4 Matriz de confusión

La matriz de confusión es una herramienta utilizada para visualizar el desempeño de un modelo de clasificación. Esta matriz compara las clases

reales con las clases predichas por el algoritmo, permitiendo identificar errores y aciertos en cada categoría.

En un problema de clasificación multiclase, como en aplicaciones BCI, la matriz de confusión organiza los resultados en filas y columnas donde:

- Las filas representan las clases reales
- Las columnas representan las clases predichas.

Cada elemento de la matriz indica cuántas muestras fueron clasificadas en una categoría específica.

En el contexto de señales EEG, esta métrica permite observar si el modelo confunde frecuentemente estados mentales, por ejemplo, si la imaginación de movimiento de la mano derecha es clasificada erróneamente como movimiento de la mano izquierda. Esto ayuda a identificar qué clases presentan mayor dificultad para el clasificador.

Además de evaluar el rendimiento general, la matriz de confusión facilita el cálculo de otras métricas derivadas como sensibilidad, especificidad, precisión por clase y recall[7], [8] .

3. METODOLOGÍA.

A continuación en la *figura 1* se presenta el flujo general de procesamiento, desde la señal cruda de EEG hasta la evaluación de los modelos clasificadores:




figura 1

3.1 Fase 1: Adquisición y Preprocesamiento de Señales

El propósito de esta fase es limpiar la señal cruda de EEG eliminando artefactos de origen muscular, ocular y de línea de potencia eléctrica, delimitando el análisis a las bandas de frecuencia donde ocurren los fenómenos de imaginación motora. Se trabaja con los registros de la base de datos PhysioNet correspondientes a los sujetos S001–S109, específicamente los archivos R04, R08 y R12 asociados a las tareas de imaginación motora [9].

Sobre la señal cruda se aplica en primer lugar un filtrado espacial CAR (Common Average Reference), que consiste en restar a cada canal el promedio instantáneo de todos los canales activos. Este procedimiento elimina el ruido ambiental de modo común y mejora la resolución espacial de la corteza motora[10]. A continuación se diseña e implementa un filtro FIR pasabanda con frecuencias de corte entre 8 Hz y 30 Hz, rango que cubre estrictamente el ritmo Mu (8–13 Hz) y el ritmo Beta (13–30 Hz), ambos responsables de la desincronización relacionada con eventos (ERD) durante la activación motora [2] . Para la implementación se emplea la librería *mne* para la lectura y manejo de los datos de EEG, y *scipy.signal* para el diseño y aplicación vectorizada del filtro.

3.2 Fase 2: Segmentación por Eventos (Épocas)

Una vez pre procesada la señal, se extraen los fragmentos de tiempo exactos denominados épocas en los que el sujeto realizaba una tarea específica, guiada por los marcadores o *cues* del protocolo experimental. Se localizan los códigos de evento en la señal: T0 para el estado de reposo, T1 para la imaginación de movimiento de la mano izquierda, y T2 para la imaginación de movimiento de la mano derecha. Para cada estímulo detectado se extrae una ventana temporal de 0 a 4 segundos posteriores al marcador de inicio[9] . En este proyecto se va a trabajar con tres clases según las recomendaciones de la guía para el proyecto. reposo (T0), imaginación de mano izquierda (T1) e imaginación de mano derecha (T2).

3.3 Fase 3: Extracción de Características

Se desarrolla una función optimizada en Python que recibe los segmentos de EEG filtrados de los canales de interés (C3, Cz y C4) y extrae una matriz de características con base en cuatro dominios complementarios. El primero es la Densidad Espectral de Potencia (PSD), calculada mediante el método de Welch (*scipy.signal.welch*), promediando la potencia en las bandas Mu (8–13 Hz) y Beta (13–30 Hz) para cada canal de forma independiente, lo que permite identificar la caída de energía —ERD— en el hemisferio contralateral a la mano imaginada[11] .

El segundo dominio comprende los parámetros de Hjorth, que miden las propiedades estadísticas de la señal y sus derivadas mediante operaciones vectoriales con NumPy: la Actividad (varianza de la señal), la Movilidad (raíz del cociente entre la varianza de la derivada y la de la señal) y la Complejidad (cociente entre la movilidad de la derivada y la de la señal)[12] . La desincronización del ritmo Mu altera la regularidad de la onda, incrementando los valores de Complejidad y Movilidad en los canales C3 o C4.

El tercer dominio es la Entropía Muestral (Sample Entropy), calculada con algoritmos vectorizados de las librerías *antropy* o *mne-features* sobre cada época. El estado de reposo presenta ritmos más predecibles (menor entropía), mientras que la imaginación motora activa las redes corticales locales aumentando el desorden de la señal. Finalmente[4] , el cuarto dominio es el Phase Locking Value (PLV), que mide la sincronización en fase entre C3 y C4 en la banda Mu mediante la Transformada de Hilbert (*scipy.signal.hilbert*), calculado como el módulo del promedio temporal del exponencial complejo de la diferencia de fases instantáneas entre ambos canales. Este índice permite cuantificar el desacoplamiento interhemisférico durante tareas motoras unilaterales.

3.4 Fase 4: Consolidación del DataFrame y Análisis Estadístico

Los resultados de la fase de extracción se consolidan en un único DataFrame de pandas, donde cada fila representa una época y las columnas incluyen el identificador del sujeto, la tarea realizada y cada una de las características calculadas. Un bucle principal recorre de forma automatizada todos los archivos de la base de datos, ejecuta el preprocesamiento, extrae las épocas y acumula las métricas en este DataFrame global.

Sujeto	Época	Tarea	mu_C3	beta_C3	...
S001	0	0	2.6..	2.3...	...
S002	1	0	4.14..	2.31..	...
S003	2	0	9.8..	1.8..	
...	...		...	...	...

Sobre este conjunto de datos se realizan dos tipos de análisis. El primero es de carácter descriptivo: se generan diagramas de caja (boxplots) y gráficos de distribución —siguiendo las recomendaciones de data-to-viz.com -- para comparar visualmente el comportamiento de cada índice entre las condiciones evaluadas. El segundo es inferencial: se aplica la prueba de normalidad de Shapiro-Wilk sobre cada grupo; si los datos son normales se ejecuta ANOVA de una vía, y si no lo son se aplica la prueba no paramétrica de Kruskal-Wallis[13] . Solo las características con diferencias estadísticamente significativas ($p < 0.05$) avanzan a la fase de clasificación.

3.5 Fase 5: Clasificación con Validación Cruzada (ML/DL)

Con el conjunto de características seleccionado se construyen, entrenan y evalúan los modelos de clasificación bajo un esquema estricto de Stratified K-Fold con $k=5$, que garantiza la representación proporcional de todas las clases en cada pliegue y evita el data leakage[7] . En cada iteración los datos se dividen en 80% entrenamiento y 20% prueba; el *StandardScaler* se ajusta exclusivamente con los datos de entrenamiento y su transformación se aplica al conjunto de prueba.

Se evalúan en paralelo cinco aproximaciones algorítmicas:

- MLP Simple (Arquitectura 1): Perceptrón Multicapa con una capa oculta de 32 neuronas (ReLU) y salida Softmax para clasificación multiclase.[8]
- MLP Profunda con Regularización (Arquitectura 2): Red con dos capas ocultas de 64 y 32 neuronas que incorpora Dropout(0.3) para prevenir el sobreajuste[8] .
- MLP con Normalización (Arquitectura 3): Configuración con activaciones LeakyReLU y capas de BatchNormalization para evaluar la convergencia frente a las arquitecturas anteriores.[8]
- SVM con kernel RBF: Modelo geométrico con función de base radial, óptimo para fronteras de decisión no lineales en espacios de alta dimensionalidad.[6]
- XGBoost: Ensamble secuencial de árboles de decisión optimizados por gradiente, capaz de capturar interacciones complejas entre los índices calculados.[14]

Para cada modelo y en cada pliegue se calculan Accuracy, F1-Score, Precisión y Recall. Al finalizar el proceso se promedian los resultados de los 5 pliegues y se grafica la Matriz de Confusión acumulada, que

permite identificar qué condiciones cognitivas presentan mayor dificultad de discriminación para el sistema BCI[7], [8] .

Antes de proceder con el entrenamiento de los modelos de aprendizaje automático, se procedió a evaluar estadísticamente la capacidad discriminativa de las señales EEG. La tabla 1 resume las preguntas de investigación y el planteamiento de las hipótesis nulas y alternativas orientadas a verificar si el tipo de tarea mental y la ubicación espacial de los electrodos (C3, C4, Cz) tienen un efecto estadísticamente significativo sobre la potencia de las bandas frecuenciales Mu y Beta, entre otros índices:

ID	Feature	Grupos	Hipótesis Nula (H_0)	Hipótesis Alternativa (H_1)
Hipótesis 4 — Hjorth: Actividad y Complejidad en C3				
4a	Hjorth Act C3	T1 vs T2	H₀: No existen diferencias significativas en la Actividad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).	H₁: Existen diferencias significativas en la Actividad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).
4b	Hjorth Act C3	T2 vs T0	H₀: No existen diferencias significativas en la Actividad de Hjorth (C3) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la Actividad de Hjorth (C3) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).
c	Hjorth Act C3	T1 vs T0	H₀: No existen diferencias significativas en la Actividad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la Actividad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).
4a	Hjorth Comp C3	T1 vs T2	H₀: No existen diferencias significativas en la Complejidad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).	H₁: Existen diferencias significativas en la Complejidad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).
4b	Hjorth Comp C3	T2 vs T0	H₀: No existen diferencias significativas en la Complejidad de Hjorth (C3) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la Complejidad de Hjorth (C3) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).
4c	Hjorth Comp C3	T1 vs T0	H₀: No existen diferencias significativas en la Complejidad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la Complejidad de Hjorth (C3) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).
Hipótesis 5 — Sample Entropy en C3				
5a	SampEn C3	T1 vs T2	H₀: No existen diferencias significativas en la entropía muestral del canal C3 entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).	H₁: Existen diferencias significativas en la entropía muestral del canal C3 entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).

5b	SampEn C3	T2 vs T0	H₀: No existen diferencias significativas en la entropía muestral del canal C3 entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la entropía muestral del canal C3 entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).
5c	SampEn C3	T1 vs T0	H₀: No existen diferencias significativas en la entropía muestral del canal C3 entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la entropía muestral del canal C3 entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).
Hipótesis 6 — Phase Locking Value (banda Mu) C3-C4				
6a	PLV Mu C3-C4	T1 vs T2	H₀: No existen diferencias significativas en el Phase Locking Value de la banda Mu (C3-C4) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).	H₁: Existen diferencias significativas en el Phase Locking Value de la banda Mu (C3-C4) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).
6b	PLV Mu C3-C4	T2 vs T0	H₀: No existen diferencias significativas en el Phase Locking Value de la banda Mu (C3-C4) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).	H₁: Existen diferencias significativas en el Phase Locking Value de la banda Mu (C3-C4) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).
6c	PLV Mu C3-C4	T1 vs T0	H₀: No existen diferencias significativas en el Phase Locking Value de la banda Mu (C3-C4) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).	H₁: Existen diferencias significativas en el Phase Locking Value de la banda Mu (C3-C4) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).
Hipótesis 7 — Índice de Lateralidad banda Mu (LI_mu)				
7a	LI_mu	T1 vs T2	H₀: No existen diferencias significativas en el Índice de Lateralidad de la banda Mu (LI_mu) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).	H₁: Existen diferencias significativas en el Índice de Lateralidad de la banda Mu (LI_mu) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).
7b	LI_mu	T2 vs T0	H₀: No existen diferencias significativas en el Índice de Lateralidad de la banda Mu (LI_mu) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).	H₁: Existen diferencias significativas en el Índice de Lateralidad de la banda Mu (LI_mu) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).
7c	LI_mu	T1 vs T0	H₀: No existen diferencias significativas en el Índice de Lateralidad de la banda Mu (LI_mu) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).	H₁: Existen diferencias significativas en el Índice de Lateralidad de la banda Mu (LI_mu) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).
Hipótesis 8— Índice de Lateralidad banda Beta (LI_beta)				
8a	LI_beta	T1 vs T2	H₀: No existen diferencias significativas en el Índice de Lateralidad de la banda Beta (LI_beta) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).	H₁: Existen diferencias significativas en el Índice de Lateralidad de la banda Beta (LI_beta) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).

8b	LI_beta	T2 vs T0	H₀: No existen diferencias significativas en el Índice de Lateralidad de la banda Beta (LI_beta) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).	H₁: Existen diferencias significativas en el Índice de Lateralidad de la banda Beta (LI_beta) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).
8c	LI_beta	T1 vs T0	H₀: No existen diferencias significativas en el Índice de Lateralidad de la banda Beta (LI_beta) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).	H₁: Existen diferencias significativas en el Índice de Lateralidad de la banda Beta (LI_beta) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).
Hipótesis 9— Diferencia de Entropía Interhemisférica (sampen_diff)				
9a	sampen_diff	T1 vs T2	H₀: No existen diferencias significativas en la diferencia de entropía muestral interhemisférica (sampen_diff) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).	H₁: Existen diferencias significativas en la diferencia de entropía muestral interhemisférica (sampen_diff) entre la imaginación de movimiento de la mano izquierda (T1) y la mano derecha (T2).
9b	sampen_diff	T2 vs T0	H₀: No existen diferencias significativas en la diferencia de entropía muestral interhemisférica (sampen_diff) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la diferencia de entropía muestral interhemisférica (sampen_diff) entre la imaginación de movimiento de la mano derecha (T2) y el estado de reposo (T0).
9c	sampen_diff	T1 vs T0	H₀: No existen diferencias significativas en la diferencia de entropía muestral interhemisférica (sampen_diff) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).	H₁: Existen diferencias significativas en la diferencia de entropía muestral interhemisférica (sampen_diff) entre la imaginación de movimiento de la mano izquierda (T1) y el estado de reposo (T0).

Tabla 1. Hipótesis de índices de clasificación.

4. ANÁLISIS DE RESULTADOS

4.1 DENSIDAD ESPECTRAL DE POTENCIA (PSD Banda Mu)

La Figura 2 presenta la distribución de la densidad espectral de potencia (PSD) en la banda Mu para los canales C3, Cz y C4 bajo las condiciones de reposo (T0), imaginación de movimiento de la mano izquierda (T1) e imaginación de movimiento de la mano derecha (T2). En general, se observa una tendencia a la disminución de la potencia Mu durante las tareas de imaginación motora respecto a la condición de reposo. Este comportamiento es consistente con el fenómeno de desincronización relacionada con eventos (ERD), ampliamente reportado en estudios de interfaces cerebro-computador, donde la activación de áreas motoras produce una reducción de la potencia de los ritmos sensoriomotores [2], [15].




figura 2

En los canales C3, Cz y C4 se observa una disminución de la potencia en la banda Mu durante las tareas de imaginación motora en comparación con la condición de reposo. Este comportamiento es consistente con la activación de áreas sensoriomotoras durante la planificación o imaginación del movimiento. Las diferencias son más evidentes en los canales laterales C3 y C4, donde se aprecia una mayor sensibilidad a la lateralización motora, mientras que Cz presenta un mayor solapamiento entre condiciones debido a su ubicación central y a la influencia de ambos hemisferios. Además, la presencia de valores atípicos y una dispersión considerable sugieren una importante variabilidad intersujeto en la respuesta cortical, un fenómeno comúnmente descrito en estudios de BCI basados en imaginación motora[16].

La Figura 2 también muestra la distribución del índice de sincronización de fase (PLV) calculado entre los canales C3 y C4 en la banda Mu. A diferencia de la PSD, las tres condiciones presentan distribuciones muy similares y un elevado grado de solapamiento. Aunque se observa una ligera disminución de la mediana durante la imaginación de movimiento de la mano izquierda, las diferencias son pequeñas en comparación con la variabilidad de los datos.

Estos resultados sugieren que la conectividad funcional medida mediante PLV experimenta modificaciones limitadas durante las tareas evaluadas, al menos en comparación con los cambios observados en la potencia espectral. En consecuencia, el PLV parece tener una menor capacidad para discriminar entre las condiciones de reposo e imaginación motora cuando se analiza de manera aislada.

4.2 DENSIDAD ESPECTRAL DE POTENCIA (PSD Banda Beta)

En los canales C3, Cz y C4 se observa una tendencia general a la disminución de la potencia en la banda Beta durante las tareas de imaginación motora respecto a la condición de reposo. Sin embargo, las diferencias entre condiciones son menos pronunciadas que las observadas en la banda Mu y existe un mayor grado de solapamiento entre las distribuciones. Aun así, los canales laterales C3 y C4 presentan una reducción consistente de la potencia durante las tareas motoras imaginadas, mientras que Cz muestra variaciones más discretas debido a su ubicación central y a la contribución simultánea de ambos hemisferios[15].




figura 3

Desde el punto de vista fisiológico, esta disminución de la potencia Beta es consistente con el fenómeno de desincronización de los ritmos sensorimotrices asociado a la preparación y representación mental del movimiento. No obstante, la elevada dispersión de los datos y la presencia de numerosos valores atípicos sugieren una importante variabilidad entre sujetos, lo que podría limitar la capacidad discriminativa de esta característica cuando se utiliza de forma aislada. En comparación con la banda Mu, la banda Beta parece mostrar una separación menos marcada entre las condiciones evaluadas, aunque continúa aportando información relevante sobre la actividad cortical relacionada con la imaginación motora [15].

4.3 PARÁMETROS DE HJORTH

La Figura 4 presenta la distribución de los parámetros de Hjorth (Actividad, Movilidad y Complejidad) calculados en los canales C3, Cz y C4 para las condiciones de reposo e imaginación motora. En general, se observa que las distribuciones de las tres condiciones presentan un elevado grado de solapamiento, especialmente en los parámetros de movilidad y complejidad, donde las medianas son prácticamente iguales entre grupos. Esto sugiere que estos índices experimentan cambios relativamente pequeños entre las tareas evaluadas y que, de manera individual, poseen una capacidad limitada para diferenciar los estados motores imaginados[12], [17].

Parámetros de Hjorth | escalas independientes por parámetro




figura 4

En el caso de la Actividad, se aprecia una ligera disminución de los valores medianos durante las tareas de imaginación motora respecto al reposo en los tres canales analizados. Este comportamiento es consistente con la reducción de potencia observada previamente en las bandas Mu y Beta, dado que la Actividad de Hjorth está directamente relacionada con la varianza de la señal. No obstante, la diferencia entre condiciones es pequeña en comparación con la dispersión de los datos y la cantidad de valores atípicos presentes, lo que evidencia una importante variabilidad entre sujetos.

Por otro lado, los parámetros de Movilidad y Complejidad muestran una notable estabilidad entre las tres condiciones. Las medianas permanecen prácticamente constantes en C3, Cz y C4, y las distribuciones presentan rangos intercuartílicos muy similares. Estos resultados indican que la estructura temporal y la complejidad de las señales EEG se mantienen relativamente conservadas entre reposo e imaginación motora, al menos bajo las métricas de Hjorth empleadas[12], [18].

En conjunto, los resultados sugieren que la Actividad de Hjorth podría aportar información complementaria relacionada con los cambios de potencia cortical asociados a la imaginación motora, mientras que la Movilidad y la Complejidad muestran una menor sensibilidad para discriminar entre las condiciones evaluadas. Por tanto, estos parámetros podrían resultar más útiles cuando se combinan con otras características, como la densidad espectral de potencia o medidas de conectividad, dentro de un sistema de clasificación multivariable[18].

4.4 ENTROPÍA MUESTRAL (SAMPEN)

La Figura 5 muestra la distribución de la entropía muestral (Sample Entropy) en los canales C3, Cz y C4 para las condiciones de reposo e imaginación motora. En términos generales, se observa una ligera tendencia al aumento de la entropía durante las tareas de imaginación de movimiento en comparación con el reposo. Aunque las diferencias entre las medianas son relativamente pequeñas y existe un importante solapamiento entre las distribuciones, esta tendencia se mantiene de forma consistente en los tres canales analizados[4], [19]




figura 5

Desde una perspectiva fisiológica, la Sample Entropy cuantifica el grado de irregularidad o imprevisibilidad de una señal. Valores más altos indican una dinámica temporal más compleja y menos repetitiva[4]. El incremento observado durante las tareas de imaginación motora puede interpretarse como una mayor complejidad de la actividad cortical asociada al procesamiento de la tarea y al reclutamiento de redes neuronales involucradas en la representación mental del movimiento. Este comportamiento coincide con la idea de que

los estados cognitivos activos suelen presentar una organización temporal más compleja que los estados de reposo[19].

Sin embargo, las diferencias entre condiciones son pequeñas en comparación con la dispersión de los datos, y las distribuciones muestran una gran superposición entre grupos. Esto sugiere que, aunque la Sample Entropy es sensible a cambios en la dinámica cerebral, su capacidad discriminativa de manera aislada podría ser limitada. Aun así, la consistencia de la tendencia observada en C3, Cz y C4 indica que esta característica puede aportar información complementaria a las medidas espectrales y a otros índices utilizados para la clasificación de estados BCI.relevantes[20].

En conjunto, los resultados sugieren que la entropía muestral captura modificaciones sutiles en la complejidad de la actividad cortical durante la imaginación motora. Si bien las diferencias no son tan marcadas como las observadas en algunos índices espectrales, esta métrica podría contribuir a mejorar el desempeño de los modelos de clasificación cuando se combina con otras características fisiológicamente[20].

4.5 VALOR DE BLOQUEO DE FASE (PLV)

La Figura 6 presenta la distribución del índice de sincronización de fase (PLV) entre los canales C3 y C4 en la banda Mu para las condiciones de reposo e imaginación motora. Los resultados muestran valores medianos muy similares entre las tres condiciones evaluadas, con una ligera disminución durante la imaginación de movimiento de la mano izquierda y una recuperación parcial durante la imaginación de la mano derecha. Sin embargo, las distribuciones presentan un amplio solapamiento y rangos intercuartílicos comparables, lo que indica que las diferencias observadas son relativamente pequeñas frente a la variabilidad de los datos[5], [21].




figura 6

Desde el punto de vista fisiológico, el PLV cuantifica el grado de sincronización de fase entre dos regiones cerebrales, proporcionando una medida de conectividad funcional. Valores elevados indican una relación de fase más estable entre las señales registradas en ambos canales, mientras que valores menores reflejan una sincronización reducida[5]. En este caso, la ligera disminución observada durante las tareas de imaginación motora podría sugerir una reorganización temporal de la comunicación entre las áreas motoras de ambos hemisferios durante la ejecución mental del movimiento[21].

No obstante, la elevada superposición entre las distribuciones y la escasa diferencia entre medianas sugieren que el PLV posee una capacidad limitada para discriminar entre las condiciones de reposo e imaginación motora cuando se utiliza de manera individual. Por tanto, aunque esta métrica aporta información sobre la conectividad funcional cortical, los resultados indican que su poder discriminativo es inferior al observado en las características espectrales de las bandas Mu y Beta[21].

En conjunto, estos hallazgos sugieren que el PLV puede constituir una característica complementaria dentro del conjunto de variables empleadas para la clasificación de estados BCI, aportando información sobre la interacción funcional entre regiones corticales, aunque probablemente con una contribución menor que las métricas basadas en potencia espectral[21].

4.6 Índice de lateralidad basado en la potencia espectral de las bandas Mu y Beta

La Figura 7 presenta la distribución del índice de lateralidad (LI) calculado a partir de la potencia espectral registrada en los canales C3 y C4 para las bandas Mu y

Beta. Este índice permite evaluar el predominio relativo de la actividad cortical entre ambos hemisferios, donde valores positivos indican una mayor contribución de C3, valores negativos reflejan un predominio de C4 y valores cercanos a cero representan una distribución simétrica de la actividad cerebral. [22].




figura 7

En ambas bandas se observa que las medianas de las tres condiciones permanecen próximas al valor de simetría ($LI = 0$), lo que indica una distribución relativamente equilibrada de la actividad cortical entre los hemisferios durante reposo e imaginación motora. Sin embargo, se aprecia una ligera tendencia hacia valores positivos durante la imaginación de movimiento de la mano izquierda y hacia valores negativos durante la imaginación de movimiento de la mano derecha. Este comportamiento es consistente con la organización contralateral del sistema motor, donde la activación asociada a cada tarea tiende a producir cambios diferenciales en las áreas sensorimotoras de ambos hemisferios[22].

A pesar de esta tendencia fisiológicamente esperada, las distribuciones presentan un amplio grado de solapamiento y una dispersión considerable entre sujetos. La variabilidad observada sugiere que la lateralización inducida por la imaginación motora no es uniforme en toda la población analizada y que las diferencias entre condiciones son relativamente sutiles. No obstante, la banda Mu parece exhibir una separación ligeramente más evidente entre las tareas motoras que la banda Beta, lo cual coincide con la importancia reconocida de los ritmos Mu en los paradigmas de imaginación motora utilizados en sistemas[23].

En conjunto, los resultados indican que el índice de lateralidad logra capturar parcialmente la reorganización espacial de la actividad cortical asociada a las tareas de imaginación motora. Aunque las diferencias observadas no son suficientemente marcadas para discriminar las condiciones de manera aislada, esta métrica aporta información complementaria sobre la distribución hemisférica de la actividad cerebral y podría incrementar el desempeño de los modelos de clasificación cuando se combina con características espectrales y de complejidad[23].

4.7 Resumen de Pruebas Estadísticas (25 Hipótesis)

Prueba: Mann-Whitney U $\alpha = 0.05$					
ID	Variable	Grupos	Prueba	Valor p	Decisión
1	PSD Mu C3	T1 vs T2	Mann-Whitney U	3.13e-02	Rechaza H_0
2	PSD Beta C4	T1 vs T2	Mann-Whitney U	7.04e-03	Rechaza H_0
3a	PSD Mu C3	T2 vs T0	Mann-Whitney U	7.42e-16	Rechaza H_0
3b	PSD Mu C3	T1 vs T0	Mann-Whitney U	2.20e-08	Rechaza H_0
5a	Hjorth Act C3	T1 vs T2	Mann-Whitney U	9.44e-02	No rechaza H_0
5b	Hjorth Act C3	T2 vs T0	Mann-Whitney U	< 1e-15	Rechaza H_0
5c	Hjorth Act C3	T1 vs T0	Mann-Whitney U	1.00e-06	Rechaza H_0
5a	Hjorth Comp C3	T1 vs T2	Mann-Whitney U	7.61e-01	No rechaza H_0
5b	Hjorth Comp C3	T2 vs T0	Mann-Whitney U	4.33e-02	Rechaza H_0
5c	Hjorth Comp C3	T1 vs T0	Mann-Whitney U	2.08e-02	Rechaza H_0
6a	SampEn C3	T1 vs T2	Mann-Whitney U	6.66e-01	No rechaza H_0
6b	SampEn C3	T2 vs T0	Mann-Whitney U	< 1e-15	Rechaza H_0
6c	SampEn C3	T1 vs T0	Mann-Whitney U	< 1e-15	Rechaza H_0
7a	PLV Mu C3-C4	T1 vs T2	Mann-Whitney U	5.90e-02	No rechaza H_0
7b	PLV Mu C3-C4	T2 vs T0	Mann-Whitney U	8.27e-01	No rechaza H_0
7c	PLV Mu C3-C4	T1 vs T0	Mann-Whitney U	1.59e-02	Rechaza H_0
8a	LI_mu	T1 vs T2	Mann-Whitney U	< 1e-15	Rechaza H_0
8b	LI_mu	T2 vs T0	Mann-Whitney U	< 1e-15	Rechaza H_0
8c	LI_mu	T1 vs T0	Mann-Whitney U	< 1e-15	Rechaza H_0
9a	LI_beta	T1 vs T2	Mann-Whitney U	< 1e-15	Rechaza H_0
9b	LI_beta	T2 vs T0	Mann-Whitney U	< 1e-15	Rechaza H_0

9c	LI_beta	T1 vs T0	Mann-Whitney U	2.20e-05	Rechaza H_0
10a	SampEn_diff	T1 vs T2	Mann-Whitney U	1.55e-03	Rechaza H_0
10b	SampEn_diff	T2 vs T0	Mann-Whitney U	9.58e-04	Rechaza H_0
10c	SampEn_diff	T1 vs T0	Mann-Whitney U	7.45e-01	No rechaza H_0

Tabla 2. Resultados de pruebas estadísticas.

Características espectrales: PSD Mu y Beta (1-3b)

La potencia en banda Mu (8–13 Hz) en C3 distingue significativamente las tres condiciones. Los p-valores extremadamente bajos en T1/T2 vs T0 confirman el fenómeno ERD: ambas imaginaciones suprimen el ritmo Mu respecto al reposo. La diferencia T1 vs T2 es significativa pero más débil ($p = 0.031$), lo esperado dado que la asimetría lateral existe pero no es tan pronunciada como la diferencia con el reposo. Estudios previos documentan que la imaginación de mano derecha produce ERD contralateral dominante en C3, mientras que la imaginación izquierda lo produce en C4, con dominancia contralateral clara en ambos casos. [24]

Parámetros de Hjorth (5a-5c)

Los parámetros de Hjorth detectan correctamente la activación motora frente al reposo, pero fallan al discriminar T1 vs T2. Esto es coherente con la teoría: la actividad y complejidad de la señal aumentan durante cualquier imaginación motora sin cambiar de forma diferenciada según la lateralidad. Son útiles para detectar si el sujeto está imaginando algo, pero no para determinar qué lado. Los parámetros de Hjorth son características basadas en la varianza de las derivadas de la señal EEG, siendo la actividad, la movilidad y la complejidad sus tres componentes principales, ampliamente utilizados como método de extracción de características en sistemas BCI.[25]

Sample Entropy (6a-6c)-(10a-10c)

SampEn en C3 aislado reproduce el mismo patrón que Hjorth: excelente para separar imaginación vs reposo, pero completamente inútil para lateralidad ($p = 0.67$). Este resultado justifica la creación de la característica SampEn_diff analizada en la sección 10. La entropía muestral es la medida de entropía más frecuentemente utilizada en sistemas BCI de imaginación motora (16.3% de los estudios revisados), gracias a su capacidad de capturar el comportamiento dinámico no lineal de las señales EEG y su robustez ante interferencias[26].

PLV Mu C3–C4

El PLV es el resultado más llamativo de la tabla: solo logra distinguir T1 vs T0, sin diferenciar T2 vs T0 ni T1 vs T2. Esto indica que la sincronía de fase interhemisférica no varía de forma consistente durante la imaginación derecha respecto al reposo, ni es suficientemente asimétrica entre condiciones laterales. Su aporte al clasificador es marginal para la tarea de lateralidad. El PLV de trial único ha sido propuesto como característica complementaria robusta para diferenciar estados de imaginación motora, derivado de las sincronías de fase a gran escala y escala local entre las áreas motoras suplementaria y primaria. [27]

Índice de Lateralidad (LI) -Mu y Beta

LI_mu y LI_beta son las características más potentes del conjunto. Al normalizar la diferencia C3–C4 sobre su suma, capturan directamente la asimetría interhemisférica. Los p-valores menores a $1e-15$ en T1 vs T2 evidencian una separación estadística extremadamente sólida: cuando se imagina el lado izquierdo, C4 suprime más el ritmo Mu (LI más positivo), y viceversa para el lado derecho. Estas dos características son las candidatas más relevantes para el clasificador BCI. El índice de lateralidad calculado sobre los canales C3/C4 en la banda 8–30 Hz toma valores entre -1 (completamente ipsilateral) y 1 (completamente contralateral), y ha demostrado correlación directa con el rendimiento del clasificador BCI en tareas de imaginación motora. [28]

4.7 Desempeño de los Modelos Clasificadores

Los cinco modelos fueron evaluados mediante Stratified K-Fold (5 folds), reportando media $\pm$ desviación estándar de cada métrica. Las matrices de confusión se calcularon sobre el último fold. A continuación se resumen los resultados obtenidos del documento:

Modelo	F1-macro	Precisión	Recall
MLP_R2	0.452 ± 0.008	0.497 ± 0.014	0.452 ± 0.007
MLP_R1	0.445 ± 0.009	0.474 ± 0.008	0.445 ± 0.009
MLP_R3	0.416 ± 0.011	0.419 ± 0.011	0.415 ± 0.010
SVM_RBF	0.447 ± 0.012	0.450 ± 0.011	0.455 ± 0.012
XGBoost	0.462 ± 0.013	0.462 ± 0.013	0.467 ± 0.014

Los resultados evidencian que ningún modelo alcanzó un desempeño de clasificación alto en términos absolutos, lo cual es consistente con la dificultad intrínseca del problema: discriminar tres condiciones cognitivas (reposo, imaginación izquierda, imaginación derecha) a partir de señales EEG con alta variabilidad intersujeto[1], [28] . Con 33 % como línea base del azar para un problema triclase, todos los modelos la superan, pero la brecha es moderada.

MLP_R2 es el modelo con el F1-macro más alto (0.452 ± 0.008) y simultáneamente la mayor Precisión (0.497 ± 0.014). La desviación estándar reducida en F1 (± 0.008) indica que su comportamiento es estable entre los distintos pliegues, lo que lo convierte en el clasificador más fiable del conjunto evaluado. Su arquitectura de una sola capa oculta (tamaño $\approx 2/3 \cdot N_{IN} + N_{OUT}$) parece suficiente para capturar las relaciones no lineales presentes en el vector de características sin incurrir en sobreajuste.

XGBoost ocupa el segundo lugar en F1-macro (0.462 cuando se considera la media, aunque con mayor std de ± 0.013) y obtiene el Recall más alto del grupo (0.467 ± 0.014). Su mayor variabilidad entre folds sugiere mayor sensibilidad a la composición del conjunto de entrenamiento, lo cual es esperable en un ensamble de árboles con 200 estimadores ante un dataset de escala moderada.

SVM_RBF logra un F1-macro de 0.447 ± 0.012 , apenas por debajo de MLP_R2, con la particularidad de que su Recall (0.455) supera a su Precisión (0.450). Esto indica que el modelo tiende a clasificar épocas de imaginación motora con algo más de sensibilidad, pero a costa de un mayor número de falsos positivos. El uso de `class_weight='balanced'` contribuye a esta característica.

MLP_R1, con estructura embudo de dos capas, obtiene un F1-macro de 0.445 ± 0.009 y una Precisión de 0.474 ± 0.008 — la segunda más alta del grupo, y con la menor desviación estándar en Precisión, lo que indica consistencia en su tasa de predicciones correctas. Sin embargo, su Recall (0.445) es el más bajo junto con MLP_R2, reflejando dificultades para detectar todas las instancias de las clases minoritarias.

MLP_R3 presenta el peor desempeño global: F1-macro de 0.416 ± 0.011 , Precisión de 0.419 ± 0.011 y Recall de 0.415 ± 0.010 . La arquitectura más grande (dos capas con activación tanh y tasa de aprendizaje adaptativa) no mejoró la generalización respecto a las redes más simples, posiblemente porque la mayor capacidad del modelo llevó a un mayor ajuste al ruido presente en los datos de entrenamiento.

En conjunto, los resultados indican que los modelos basados en MLP con arquitecturas moderadas (MLP_R2) o el ensamble XGBoost ofrecen el mejor balance entre rendimiento y estabilidad para este problema. La diferencia relativamente pequeña entre modelos sugiere que el factor limitante no es la arquitectura del clasificador sino la calidad y cantidad de información discriminativa disponible en el vector de características construido — lo cual refuerza la importancia del preprocesamiento y la selección estadística de características realizada en las fases anteriores del pipeline.[1], [24].

Matriz de confusión




Figura 8

La Figura 8 presenta las matrices de confusión obtenidas para los modelos MLP_R2, MLP_R1, MLP_R3, SVM con núcleo RBF y XGBoost, correspondientes al último pliegue de validación cruzada. Los resultados muestran que el mejor desempeño fue alcanzado por el modelo MLP_R2, con una exactitud de 52.7 %, seguido por MLP_R1 con 52.0 %. Los modelos MLP_R3 y XGBoost obtuvieron una exactitud similar de 47.9 %, mientras que SVM_RBF presentó el rendimiento más bajo con 45.1 %. Aunque los valores de exactitud se encuentran por encima del nivel esperado para una clasificación aleatoria de tres clases (33.3 %), las diferencias entre modelos sugieren una capacidad moderada para discriminar entre las condiciones de reposo e imaginación motora.

Figura 8. Matrices de confusión de los modelos evaluados para la clasificación de las condiciones de reposo (T0), imaginación de movimiento de la mano izquierda (T1) e imaginación de movimiento de la mano derecha (T2).

En todas las matrices se observa que la clase Reposo (T0) es la mejor identificada. Por ejemplo, el modelo MLP_R2 clasifica correctamente 768 de 983 muestras de reposo, mientras que los errores se distribuyen principalmente hacia las clases de imaginación motora. Este comportamiento indica que las características extraídas permiten distinguir con relativa facilidad los estados de reposo respecto a los estados activos, lo cual es coherente con las diferencias observadas previamente en las características espectrales de las bandas Mu y Beta[24].

Por el contrario, las mayores dificultades aparecen al diferenciar entre imaginación de movimiento de la mano izquierda (T1) e imaginación de movimiento de la mano derecha (T2). En todos los modelos existe una elevada tasa de confusión entre ambas clases, evidenciada por el considerable número de muestras clasificadas erróneamente entre T1 y T2. Este resultado sugiere que las diferencias neurofisiológicas asociadas a la lateralización motora son más sutiles que las diferencias entre reposo e imaginación motora, lo que coincide con el análisis descriptivo realizado sobre las características extraídas[24], [28].

De manera general, los resultados indican que las redes neuronales multicapa (MLP) lograron capturar mejor las relaciones no lineales presentes en las características seleccionadas, superando ligeramente a SVM_RBF y XGBoost. Sin embargo, la magnitud de las mejoras es relativamente reducida, lo que sugiere que existe un límite en la separabilidad de las clases utilizando únicamente las características consideradas en este estudio. En consecuencia, futuras mejoras podrían obtenerse mediante la incorporación de características espaciales adicionales, técnicas avanzadas de selección de atributos o arquitecturas de aprendizaje profundo capaces de explotar con mayor eficacia la información temporal y espacial de las señales EEG.

4.8 Selección y Justificación del Mejor Modelo

Con base en el análisis conjunto del F1-macro promedio en validación cruzada y el comportamiento observado en la matriz de confusión del Fold 5, XGBoost se consolida como el modelo con mejor desempeño global del conjunto evaluado.

En términos de F1-macro, XGBoost alcanza un valor promedio de 0.462 ± 0.013 , el más alto entre los cinco modelos, superando a MLP_R2 (0.452), SVM_RBF (0.447), MLP_R1 (0.445) y MLP_R3 (0.416). Esta métrica es particularmente relevante en un problema triclase con clases de distinto tamaño, ya que penaliza el mal desempeño en las clases minoritarias (T1 y T2) y no se ve inflada por el buen desempeño en la clase mayoritaria (T0). El hecho de que XGBoost lidere en esta métrica indica que es el modelo que mejor equilibra la capacidad de detectar correctamente los tres estados mentales de forma simultánea.

El análisis de la matriz de confusión del Fold 5 refuerza esta conclusión. XGBoost clasifica correctamente 526 épocas de reposo (recall T0 $\approx 53.5\%$), 207 de imaginación izquierda (recall T1 $\approx 41.9\%$) y 208 de imaginación derecha (recall T2 $\approx 42.8\%$), mostrando la distribución de aciertos más equilibrada entre las tres clases. A diferencia de los modelos MLP simples, que concentran su desempeño en T0 a costa de recalls inferiores al 30% en T1 y T2, XGBoost mantiene una capacidad discriminativa consistente en las tres clases. Esta distribución equilibrada de predicciones correctas es precisamente la que se refleja en su F1-macro superior, y es la propiedad más deseable en un sistema BCI donde los tres estados tienen igual importancia funcional para el usuario.

.

5. CONCLUSIONES

- Las características basadas en el Índice de Lateralidad (LI_mu y LI_beta) demostraron ser las más discriminativas del conjunto evaluado, con p-valores menores a $1e-15$ en la comparación T1 vs T2, reafirmando la importancia de la asimetría interhemisférica como firma neural de la imaginación motora unilateral.[11]
- La PSD en banda Mu confirma el fenómeno ERD de forma robusta ($p < 1e-16$ para T0 vs T1/T2), constituyendo el indicador espectral con mayor capacidad discriminativa global.[11]
- Los parámetros de Hjorth, la SampEn individual y el PLV muestran capacidad limitada para discriminar lateralidad (T1 vs T2) de manera aislada, aunque aportan información complementaria para separar imaginación de reposo.[11,20]

- Los resultados obtenidos mediante validación cruzada Stratified K-Fold ($k=5$) evidencian que ningún modelo alcanza un desempeño de clasificación alto en términos absolutos, lo cual es consistente con la complejidad intrínseca del problema: discriminar tres estados mentales a partir de señales EEG con alta variabilidad intersujeto. No obstante, todos los modelos superan la línea base del azar (33.3%) para un problema triclase, lo que confirma la capacidad discriminativa del conjunto de características extraído. [20]
- XGBoost se establece como el mejor modelo global, con el F1-macro promedio más alto del conjunto (0.462 ± 0.013) y el recall más elevado (0.467 ± 0.014), demostrando la distribución de aciertos más equilibrada entre las tres clases en la matriz de confusión del Fold 5. Su arquitectura de ensamble de árboles le permite capturar interacciones complejas entre los índices de lateralidad, parámetros espectrales y métricas de complejidad que los modelos MLP simples no logran explotar con la misma eficiencia[20].

6. REFERENCIAS

- [1] F. Lotte, M. Congedo, A. Lécuyer, F. Lamarche and B. Arnaldi, “A review of classification algorithms for EEG-based brain–computer interfaces,” *Journal of Neural Engineering*, vol. 4, no. 2, pp. R1–R13, 2007. <https://doi.org/10.1088/1741-2560/4/2/R01>
- [2] G. Pfurtscheller and F. H. Lopes da Silva, “Event-related EEG/MEG synchronization and desynchronization: basic principles,” *Clinical Neurophysiology*, vol. 110, no. 11, pp. 1842–1857, 1999. [https://doi.org/10.1016/S1388-2457\(99\)00141-8](https://doi.org/10.1016/S1388-2457(99)00141-8)
- [3] G. Pfurtscheller and C. Neuper, “Motor imagery and direct brain-computer communication,” *Proceedings of the IEEE*, vol. 89, no. 7, pp. 1123–1134, 2001. <https://doi.org/10.1109/5.939829>
- [4] J. S. Richman and J. R. Moorman, “Physiological time-series analysis using approximate entropy and sample entropy,” *American Journal of Physiology-Heart and Circulatory Physiology*, vol. 278, no. 6, pp. H2039–H2049, 2000. <https://doi.org/10.1152/ajpheart.2000.278.6.H2039>
- [5] J.-P. Lachaux, E. Rodriguez, J. Martinerie and F. J. Varela, “Measuring phase synchrony in brain signals,” *Human Brain Mapping*, vol. 8, no. 4, pp. 194–208, 1999. [https://doi.org/10.1002/\(SICI\)1097-0193\(1999\)8:4](https://doi.org/10.1002/(SICI)1097-0193(1999)8:4)
- [6] A. L. Goldberger, L. A. N. Amaral, L. Glass et al., “PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals,” *Circulation*, vol. 101, no. 23, pp. e215–e220, 2000. <https://doi.org/10.1161/01.CIR.101.23.e215>

- [7] B. Blankertz, G. Dornhege, M. Krauledat, K.-R. Müller and G. Curio, “The non-invasive Berlin Brain–Computer Interface: Fast acquisition of effective performance in untrained subjects,” *NeuroImage*, vol. 37, no. 2, pp. 539–550, 2007. <https://doi.org/10.1016/j.neuroimage.2007.01.051>
- [8] M. Ahn and S. C. Jun, “Performance variation in motor imagery brain–computer interface: A brief review,” *Journal of Neuroscience Methods*, vol. 243, pp. 103–110, 2015. <https://doi.org/10.1016/j.jneumeth.2015.01.033>
- [9] M. Teplan, “Fundamentals of EEG measurement,” *Measurement Science Review*, vol. 2, no. 2, pp. 1–11, 2002. <http://www.measurement.sk/2002/S2/Teplan.pdf>
- [10] M. A. López-Gordo, D. Sánchez-Morillo and F. Pelayo Valle, “Dry EEG Electrodes,” *Sensors*, vol. 14, no. 7, pp. 12847–12870, 2014. <https://doi.org/10.3390/s140712847>
- [11] M. Clerc, L. Bougrain and F. Lotte, *Brain-Computer Interfaces 1: Foundations and Methods*. London, UK: ISTE Ltd / Wiley, 2016. <https://doi.org/10.1002/9781119144977>
- [12] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006. <https://github.com/Benlau93/Data-Science-Curriculum/blob/master/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>
- [13] A. C. Müller and S. Guido, *Introduction to Machine Learning with Python*. Sebastopol, CA, USA: O’Reilly Media, 2016. [https://www.nrigroupindia.com/e-book/Introduction%20to%20Machine%20Learning%20with%20Python%20\(%20PDFDrive.com%20\)-min.pdf](https://www.nrigroupindia.com/e-book/Introduction%20to%20Machine%20Learning%20with%20Python%20(%20PDFDrive.com%20)-min.pdf)
- [14] I. Goodfellow, Y. Bengio and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. <https://www.deeplearningbook.org/>
- [15] B. Hjorth, “EEG analysis based on time domain properties,” *Electroencephalography and Clinical Neurophysiology*, vol. 29, no. 3, pp. 306–310, 1970. [https://doi.org/10.1016/0013-4694\(70\)90143-4](https://doi.org/10.1016/0013-4694(70)90143-4)
- [16] M. M. Iscan, V. V. Nikulin and N. G. van Luitelaar, “Classification of mental tasks using Hjorth parameters,” *Knowledge-Based Systems*, vol. 56, pp. 213–220, 2014. <https://doi.org/10.1016/j.knosys.2013.02.014>
- [17] S. Güler and E. D. Übeyli, “Adaptive neuro-fuzzy inference system for classification of EEG signals using Hjorth parameters,” *Expert Systems with Applications*, vol. 32, no. 1, pp. 79–86, 2007. <https://doi.org/10.1016/j.eswa.2006.02.005>
- [18] N. Kannathal, U. R. Acharya, C. M. Lim and P. K. Sadasivan, “Characterization of EEG signals using approximate entropy and sample entropy,” *Computer Methods and Programs in Biomedicine*, vol.

80, no. 2, pp. 187–196, 2005.

<https://doi.org/10.1016/j.cmpb.2005.06.005>

[19] Y. Chua, V. Chandran, U. R. Acharya and C. M. Lim, “Application of higher order spectra to identify epileptic EEG,” *Computer Methods and Programs in Biomedicine*, vol. 95, no. 1, pp. 11–19, 2009.

<https://doi.org/10.1016/j.cmpb.2008.12.007>

[20] Y. Song and J. Crowcroft, “A comparative study of EEG classification using neural network and entropy-based features,” *Expert Systems with Applications*, vol. 39, no. 8, pp. 7066–7075, 2012.

<https://doi.org/10.1016/j.eswa.2012.01.102>

[21] F. Varela, J.-P. Lachaux, E. Rodriguez and J. Martinerie, “The brainweb: phase synchronization and large-scale integration,” *Nature Reviews Neuroscience*, vol. 2, no. 4, pp. 229–239, 2001.

<https://doi.org/10.1038/35067550>

[22] C. Neuper, G. R. Müller-Putz, R. Scherer and G. Pfurtscheller, “Motor imagery and EEG-based control of spelling devices and neuroprostheses,” in *Progress in Brain Research*, vol. 159, pp. 393–409, 2006.

[https://doi.org/10.1016/S0079-6123\(06\)59006-5](https://doi.org/10.1016/S0079-6123(06)59006-5)

[23] G. Pfurtscheller and C. Neuper, “Motor imagery activates primary sensorimotor area in humans,” *Neuroscience Letters*, vol. 239, no. 2–3, pp. 65–68, 1997.

[https://doi.org/10.1016/S0304-3940\(97\)00889-6](https://doi.org/10.1016/S0304-3940(97)00889-6)

[24] G. Pfurtscheller, C. Brunner, A. Schlögl and F. H. Lopes da Silva, “Mu rhythm (de)synchronization and EEG single-trial classification of different motor imagery tasks,” *NeuroImage*, vol. 31, no. 1, pp. 153–159, 2006.

<https://www.sciencedirect.com/science/article/abs/pii/S1053811905025140>

[25] A. A. Al-Nafjan, M. Hosny, A. Al-Ohali and A. Al-Wabil, “Classification of mental task EEG records using Hjorth parameters,” in *International Conference on Informatics, Health & Technology (ICIHT)*, 2017.

<https://ieeexplore.ieee.org/document/7960608/>

[26] M. Al-Qazzaz et al., “The Application of Entropy in Motor Imagery Paradigms of Brain–Computer Interfaces,” *Brain Sciences*, vol. 15, no. 2, 2025.

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC11853529/>

[27] M. Grosse-Wentrup, C. Liefhold, K. Gramann and M. Buss, “Phase Synchrony Measurement in Motor Cortex for Classifying Single-Trial EEG during Motor Imagery,” in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2008.

<https://ieeexplore.ieee.org/document/4461688/>

[28] Y. Wang et al., “The Differences Between Motor Attempt and Motor Imagery in Brain–Computer Interface Accuracy and Event-Related Desynchronization of Patients With Hemiplegia,” *Frontiers in*

Neuroscience, vol. 15, 2021.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC8602190/>